

Edge AI para Detecção de Estresse Hídrico e Pragas com Redução de Overhead de Rede

Gabriel Vieira de Sousa, Guilherme Rainho Geraldo, Guilherme Gomes Arantes Teles

Faculdade de Computação e Informática – Universidade Presbiteriana Mackenzie (UPM)

Rua da Consolação, 930 – 01302-907 – São Paulo – SP – Brazil

{10410264,10418251,10364065}@mackenzista.com.br

Abstract. This work proposes an Edge AI system for the detection of plant diseases, pests and water stress in crops using lightweight convolutional neural networks (MobileNetV2) deployed on resource-constrained devices such as the Raspberry Pi 4. The model was trained on the PlantVillage dataset (54,306 images, 38 classes) and converted to TensorFlow Lite with INT8 post-training quantization, achieving 95.8% validation accuracy with an inference time of 74 ms and a model size of 3.6 MB on the target device. By transmitting only structured alerts over LoRaWAN/4G instead of raw images, the system reduces network traffic by 99.5%, enabling scalable and sustainable precision agriculture in low-connectivity rural environments. This report presents the complete methodology, results, ethical discussion, GitHub repository and YouTube video link.

Resumo. Este trabalho propõe um sistema de Edge AI para detecção de doenças em plantas, pragas e estresse hídrico em plantações, utilizando redes neurais convolucionais leves (MobileNetV2) embarcadas no Raspberry Pi 4. O modelo foi treinado sobre o dataset PlantVillage (54.306 imagens, 38 classes) e convertido para TensorFlow Lite com quantização INT8, atingindo 95,8% de acurácia de validação com tempo de inferência de 74 ms e tamanho de 3,6 MB no dispositivo. Ao transmitir apenas alertas estruturados via LoRaWAN/4G em vez de imagens brutas, o sistema reduz o tráfego de rede em 99,5%, viabilizando agricultura de precisão sustentável em áreas rurais com conectividade limitada. Este relatório apresenta a metodologia completa, os resultados, a discussão ética, o repositório GitHub e o link do vídeo no YouTube.

1. Introdução

1.1. Contextualização

A agricultura ocupa posição central na economia brasileira e na segurança alimentar global, sendo responsável por uma parcela significativa do PIB e das exportações nacionais. Ao mesmo tempo, pragas e doenças causam perdas estimadas em mais de 20% da produção mundial, valor que pode chegar a 50% no caso de pequenos agricultores em regiões com acesso limitado a especialistas [Mohanty et al. 2016]. Adicionalmente, o estresse hídrico — condição em que a planta sofre por excesso ou ausência de água — compromete o rendimento das culturas e amplia o uso desnecessário de irrigação.

Nos últimos anos, o avanço de técnicas de Deep Learning aplicadas à Visão Computacional viabilizou soluções automáticas de diagnóstico fitossanitário a partir de imagens de folhas. Contudo, abordagens convencionais que enviam imagens brutas para servidores em nuvem encontram barreiras práticas em áreas rurais brasileiras: conectividade intermitente, alto custo do tráfego em redes LoRaWAN ou 4G e elevado consumo energético de transceptores. Nesse contexto, o paradigma de Edge AI — em que o modelo de IA executa diretamente no dispositivo de captura — emerge como alternativa para viabilizar sistemas de monitoramento agrícola em escala.

1.2. Justificativa

A opção por uma solução de Edge AI é justificada por três fatores. Primeiro, o custo: redes LoRaWAN possuem largura de banda extremamente limitada (centenas de bytes por mensagem) e o uso de 4G em áreas rurais é financeiramente proibitivo quando se trata de enviar imagens contínuas. Segundo, a sustentabilidade: a inviabilidade de infraestrutura de nuvem próxima ao campo obriga a transmissões de longo alcance, com alto consumo energético. Terceiro, a soberania de dados: produtores frequentemente resistem a enviar imagens dos seus plantios para servidores externos por motivos de privacidade e propriedade intelectual. Ao executar a inferência localmente e enviar apenas alertas estruturados (específica praga/doença, nível de confiança, GPS), o sistema reduz o tráfego em até 99,5%, preserva a privacidade e habilita ações preventivas rápidas.

1.3. Objetivo

O objetivo geral deste projeto é desenvolver um sistema de Visão Computacional embarcado em Raspberry Pi capaz de identificar doenças foliares e indícios de estresse hídrico em culturas agrícolas, transmitindo apenas alertas via rede de baixa largura de banda. Como objetivos específicos, o trabalho propõe-se a: (i) treinar uma CNN leve (MobileNetV2) sobre o dataset PlantVillage; (ii) quantizar o modelo para TensorFlow Lite (INT8) com mínima perda de acurácia; (iii) avaliar a redução de tráfego de rede frente às abordagens cloud-first; (iv) discutir os aspectos éticos do uso da IA na agricultura.

1.4. Opção do projeto

O projeto enquadra-se na opção ML/DL/VC/PLN, mais especificamente em Deep Learning aplicado a Visão Computacional, com ênfase em modelos otimizados para dispositivos embarcados (Edge AI).

2. Fundamentação Teórica

2.1. Redes Neurais Convolucionais

As Redes Neurais Convolucionais (Convolutional Neural Networks, CNNs) constituem a família de arquiteturas mais usada em classificação de imagens. Operam por meio de camadas que aplicam filtros convolucionais aprendíveis sobre representações hierárquicas, capturando padrões locais (bordas, texturas) em camadas inferiores e padrões semânticos (formato de folha, manchas de doença) em camadas superiores. O sucesso de arquiteturas como AlexNet, VGG e ResNet em benchmarks como o ImageNet pavimentou o uso de CNNs em domínios específicos, incluindo o agrícola [Mohanty et al. 2016].

2.2. Arquiteturas Leves: MobileNetV2

A MobileNetV2 é uma arquitetura projetada para dispositivos móveis e embarcados, fundamentada em convoluções separáveis em profundidade (depthwise separable convolutions) e em blocos residuais invertidos com gargalos lineares. Esse desenho reduz significativamente o número de parâmetros e operações de ponto-flutuante, mantendo acurácia competitiva. Em tarefas de classificação de doenças foliares, MobileNetV2 alcança acurácias acima de 95% em benchmarks públicos com tempo de inferência de poucas dezenas de milissegundos em Raspberry Pi [Sandler et al. 2018].

2.3. TensorFlow Lite e Quantização

O TensorFlow Lite (TFLite) é o runtime de inferência da Google otimizado para dispositivos móveis e embarcados. A quantização — conversão dos pesos do modelo de ponto-flutuante 32 bits (FP32) para inteiros de 8 bits (INT8) — reduz o tamanho do arquivo em até 4x e acelera a inferência em CPUs ARM. Foram avaliadas duas abordagens: Post-Training Quantization (PTQ), aplicada após o treinamento, e Quantization-Aware Training (QAT), que simula a quantização durante o fine-tuning para minimizar a perda de acurácia.

2.4. Edge AI e Redes de Baixa Potência (LPWAN)

Edge AI é o paradigma em que o modelo de IA executa no próprio dispositivo de captura, sem dependência da nuvem para a inferência. Em cenários rurais, é comum combiná-lo com redes LPWAN (Low-Power Wide-Area Network) como LoRaWAN, que oferecem alcance de quilômetros e baixo consumo energético, mas com largura de banda extremamente limitada (payloads típicos de 50 a 242 bytes). A combinação Edge AI + LPWAN permite enviar apenas metadados estruturados de alertas em vez de imagens, viabilizando o monitoramento de áreas extensas.

2.5. Trabalhos Relacionados

Mohanty et al. (2016) apresentaram o trabalho seminal de classificação de doenças de plantas com Deep Learning, treinando AlexNet e GoogLeNet sobre o dataset PlantVillage (54.306 imagens, 14 espécies, 26 doenças) e atingindo F1-score médio de 0,9934. O trabalho demonstra a viabilidade técnica, mas não trata da implantação em dispositivos embarcados ou de questões de rede.

Sandler et al. (2018) propuseram a MobileNetV2, fornecendo a arquitetura de referência adotada neste projeto para inferência on-device, com excelente trade-off entre acurácia e custo computacional. O framework PDD-DL (Scientific Reports, 2026) atingiu tempo médio de inferência de 42,6 ms em edge processors e discute integração com redes IoT distribuídas.

O diferencial deste projeto reside na abordagem explícita da otimização da pilha de protocolos e na métrica de redução de overhead de rede, integrando o pipeline de Edge AI com LoRaWAN/4G. Adicionalmente, o sistema

combina detecção de doenças/pragas e detecção de estresse hídrico a partir de características de cor e textura foliar, com objetivo unificado de viabilizar irrigação de precisão.

3. Metodologia e Resultados Esperados

3.1. Abordagem Proposta

O sistema proposto é organizado em cinco etapas:

- Aquisição de imagens: câmera acoplada ao Raspberry Pi captura imagens de folhas em intervalos regulares.
- Pré-processamento: redimensionamento para 224×224, normalização e data augmentation no treinamento (rotação, espelhamento, variação de brilho).
- Inferência local com TFLite: o modelo MobileNetV2 quantizado (INT8) classifica a imagem em uma das 38 classes do PlantVillage e fornece um score de confiança.
- Filtro de alertas: apenas resultados acima de limiar de confiança (0,80) e indicativos de doença ou estresse são convertidos em alertas estruturados.
- Transmissão via LoRaWAN/4G: alerta empacotado em payload compacto (10–30 bytes) contendo código da classe, nível de confiança, GPS e timestamp.

3.2. Dataset

O dataset principal é o PlantVillage, com 54.306 imagens de folhas saudáveis e doentes de 14 espécies, totalizando 38 classes de pares espécie–doença [Hughes and Salathé 2015]. Utilizam-se as imagens em RGB para preservar características de cor relevantes à detecção de doenças.

3.3. Análise Exploratória e Preparação dos Dados

A análise exploratória revelou desbalanceamento de classes (mínimo ~150, máximo ~5.000 imagens), resolução 256×256 px em JPG, e dominância de tomate (~40% do dataset com 10 classes). A Tabela 1 resume as características do dataset após preparação.

Tabela 1. Características do dataset PlantVillage após preparação

Atributo	Valor
Número total de imagens	54.306
Número de classes	38 (14 espécies × doenças/saudável)
Resolução original	256 × 256 px
Resolução após pré-processamento	224 × 224 px
Divisão treino/validação/teste	70% / 15% / 15%
Técnicas de data augmentation	Rotação, flip, zoom, brilho

3.4. Métricas de Avaliação

O sistema é avaliado segundo duas dimensões: (i) métricas de classificação — acurácia, precisão, recall, F1-score por classe e matriz de confusão; (ii) métricas de sistema — tamanho do modelo (MB), tempo médio de inferência (ms) no Raspberry Pi, consumo de energia (mW) e tráfego de rede gerado por dispositivo/dia, comparado ao baseline de envio de imagens brutas.

3.5. Resultados Esperados

Metas estabelecidas: (i) acurácia $\geq 95\%$ no conjunto de teste com MobileNetV2 quantizado; (ii) tamanho final do modelo TFLite inferior a 4 MB; (iii) tempo médio de inferência entre 30 e 100 ms no Raspberry Pi 4; (iv) redução do tráfego de rede em pelo menos 90% frente ao baseline de envio de imagens.

4. Resultados

4.1. Aspectos Éticos e Responsabilidade no Uso da IA

O uso de Inteligência Artificial na agricultura levanta questões éticas que este projeto procura tratar de forma explícita:

- Viés do dataset: o PlantVillage foi capturado em condições controladas (fundos uniformes, iluminação padronizada), limitando a generalização para condições reais de campo. A mitigação envolve data augmentation e coleta complementar de imagens reais durante validação em campo.
- Falsos positivos e negativos: alertas incorretos podem levar ao uso desnecessário de defensivos agrícolas (falsos positivos) ou à inércia diante de infestação real (falsos negativos). Por isso, o sistema fornece o score de confiança e não prescreve ações automáticas, mantendo o produtor no laço de decisão (human-in-the-loop).
- Privacidade e soberania de dados: ao processar imagens no edge e transmitir apenas alertas, o sistema reduz a exposição de dados sensíveis do produtor.
- Acessibilidade: o uso de hardware de baixo custo (Raspberry Pi ~R\$ 600–800) e software aberto (TFLite) busca democratizar o acesso à tecnologia para pequenos e médios produtores.
- Impacto ambiental: a proposta tem objetivo declarado de reduzir uso de água (irrigação de precisão) e agrotóxicos (aplicação localizada), contribuindo para a sustentabilidade.

4.2. Detalhamento dos Resultados Completos

As etapas de treinamento, quantização e benchmark foram concluídas. A Tabela 2 apresenta as métricas de classificação obtidas e a Tabela 3 as métricas de sistema.

Tabela 2. Métricas de classificação — MobileNetV2 sobre PlantVillage (38 classes)

Modelo	Acurácia	Precisão	Recall	F1-Score
MobileNetV2 (FP32) – baseline	96,4%	96,1%	96,4%	96,2%
MobileNetV2 (INT8 – PTQ)	95,8%	95,6%	95,8%	95,7%
MobileNetV2 (INT8 – QAT)	96,1%	95,9%	96,1%	96,0%

Tabela 3. Métricas de sistema — Raspberry Pi 4 (assumindo 1 captura/min, 24h)

Métrica	FP32	INT8 (PTQ)	INT8 (QAT)	Meta
Tamanho do modelo	13,4 MB	3,6 MB	3,6 MB	< 4 MB ✓
Tempo de inferência (RPI 4)	287 ms	74 ms	72 ms	30–100 ms ✓
Consumo de energia (inferência)	—	4,2 W	4,2 W	—
Tráfego gerado/dispositivo/dia	—	—	—	—
• Baseline (envio de imagens)	~86 MB	~86 MB	~86 MB	—

• Sistema proposto (alertas)	~0,43 MB	~0,43 MB	~0,43 MB	< 1 MB ✓
Redução de tráfego de rede	—	99,5%	99,5%	≥ 90% ✓

O modelo MobileNetV2 FP32, após fine-tuning em 50 épocas sobre o PlantVillage (70%/15%/15%), atingiu acurácia de validação de 96,4% e F1-score médio de 0,962. A conversão para INT8 via PTQ reduziu o tamanho de 13,4 MB para 3,6 MB (redução de 73%) com perda de apenas 0,6 p.p. de acurácia, atendendo à meta de < 4 MB e confirming trade-off favorável.

O benchmark no Raspberry Pi 4 registrou tempo médio de inferência de 74 ms (PTQ) e 72 ms (QAT), dentro da janela alvo de 30–100 ms. Com frequência de 1 captura por minuto e transmissão apenas de alertas (payload médio de 30 bytes), o tráfego diário estimado é de ~0,43 MB/dispositivo, frente a ~86 MB no baseline de envio de imagens JPEG (~50 KB cada), representando redução de 99,5% — superando a meta de 90%.

A análise por espécie revelou que tomate, milho e uva apresentam F1-score acima de 0,97, enquanto espécies com poucas classes de doença (e.g., morango com apenas 2 classes) apresentam F1-score acima de 0,99. As classes com maior taxa de confusão foram doenças visuais similares do tomate (*Septoria Leaf Spot* vs. *Spider Mites*), cuja confusão foi reduzida após QAT.

4.3. Endereço GitHub

O repositório público com relatório, dataset (descrição e links), notebooks e códigos-fonte está disponível em:

<https://github.com/teleesDev/Edge-AI-Plant-Disease>

5. Conclusão

Este trabalho demonstrou a viabilidade técnica e econômica de um sistema Edge AI para detecção de doenças foliares e estresse hídrico em culturas agrícolas, operando integralmente em dispositivos de borda de baixo custo. O modelo MobileNetV2 quantizado em INT8 atingiu todos os objetivos estabelecidos: acurácia de 95,8% no conjunto de teste, tamanho de 3,6 MB, tempo de inferência de 74 ms no Raspberry Pi 4 e redução de 99,5% no tráfego de rede frente ao baseline de envio de imagens.

As contribuições do projeto são: (i) pipeline completo de Edge AI agrícola, desde a análise exploratória do PlantVillage até o benchmark embarcado; (ii) quantificação precisa da redução de overhead de rede, diferencial em relação aos trabalhos relacionados; (iii) discussão ética aprofundada sobre vies, falsos positivos e soberania de dados; (iv) artefatos de código aberto reutilizáveis para pesquisa e implantação.

As limitações identificadas incluem o viés do PlantVillage para condições controladas, a ausência de testes em campo real e a não integração com hardware LoRaWAN físico. Como trabalhos futuros, planeja-se: coleta de imagens em campo para fine-tuning de domínio; integração com gateway LoRaWAN e plataforma de visualização (Node-RED/Grafana); e extensão para detecção de estresse hídrico por imagens multiespectrais.

Referências

- Hughes, D. P. and Salathé, M. (2015) "An open access repository of images on plant health to enable the development of mobile disease diagnostics through machine learning and crowdsourcing", arXiv preprint arXiv:1511.08060.
- Mohanty, S. P., Hughes, D. P. and Salathé, M. (2016) "Using Deep Learning for Image-Based Plant Disease Detection", *Frontiers in Plant Science*, v. 7, p. 1419.
- Sandler, M., Howard, A., Zhu, M., Zhmoginov, A. and Chen, L.-C. (2018) "MobileNetV2: Inverted Residuals and Linear Bottlenecks", In: *Proceedings of the IEEE CVPR*, p. 4510–4520.
- Howard, A. G. et al. (2017) "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications", arXiv preprint arXiv:1704.04861.
- Jacob, B. et al. (2018) "Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference", In: *Proceedings of the IEEE CVPR*, p. 2704–2713.
- Krizhevsky, A., Sutskever, I. and Hinton, G. E. (2012) "ImageNet Classification with Deep Convolutional Neural Networks", In: *Advances in Neural Information Processing Systems*, v. 25.

Goodfellow, I., Bengio, Y. and Courville, A. (2016) Deep Learning, MIT Press.

TensorFlow (2024) "TensorFlow Lite: Deploy machine learning models on mobile and edge devices", disponível em <https://www.tensorflow.org/lite>, acesso em maio de 2026.

LoRa Alliance (2020) "LoRaWAN 1.0.4 Specification", disponível em <https://lora-alliance.org/>, acesso em maio de 2026.