

Edge AI para Detecção de Estresse Hídrico e Pragas com Redução de Overhead de Rede

Gabriel Vieira de Sousa¹ Guilherme Rainho Geraldo¹
Prof. Dr. Anderson Adaime de Borba¹

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

<10410264@mackenzista.com.br, 10418251@mackenzista.com.br>
<anderson.borba@mackenzie.br>

2026

Resumo

Este trabalho investiga o uso de Edge AI para monitoramento agrícola em cenários com conectividade limitada, com foco na classificação de doenças foliares e no suporte à identificação de condições de estresse em plantas sem depender do envio contínuo de imagens à nuvem. A proposta emprega a arquitetura MobileNetV2, treinada sobre o dataset PlantVillage, com 54.306 imagens distribuídas em 38 classes, e posteriormente convertida para TensorFlow Lite com quantização INT8 por Post-Training Quantization (PTQ) e Quantization-Aware Training (QAT). O pipeline foi estruturado para executar a inferência localmente e transmitir somente alertas compactos por redes de baixa largura de banda. Nos resultados oficiais reportados para o treinamento completo de 50 épocas, o modelo FP32 alcançou 96,4% de acurácia; as versões INT8 PTQ e QAT obtiveram, respectivamente, 95,8% e 96,1%, com modelos de 3,6 MB. A latência projetada para Raspberry Pi 4 foi de 74 ms no PTQ e 72 ms no QAT, enquanto a redução analítica do tráfego de rede alcançou 99,5%. Uma reprodução adicional com 1.824 imagens confirmou a execução ponta a ponta do pipeline e evidenciou limitações de generalização e de quantização em amostras reduzidas.

Palavras-chave: Edge AI; agricultura de precisão; visão computacional; MobileNetV2; TensorFlow Lite; computação de borda.

Abstract

This study investigates the use of Edge AI for agricultural monitoring in low-connectivity environments, focusing on leaf-disease classification and support for identifying plant stress conditions without continuous transmission of raw images to the cloud. The proposed approach uses MobileNetV2 trained on the PlantVillage dataset, containing 54,306 images across 38 classes, and converted to TensorFlow Lite with INT8 Post-Training Quantization (PTQ) and Quantization-Aware Training (QAT). The pipeline performs inference locally and transmits only compact alerts over low-bandwidth networks. In the official results reported for the complete 50-epoch training, the FP32 model achieved 96.4% accuracy, while INT8 PTQ and INT8 QAT

achieved 95.8% and 96.1%, respectively, with 3.6 MB model files. Raspberry Pi 4 latency was estimated at 74 ms for PTQ and 72 ms for QAT, and the analytical network-traffic reduction reached 99.5%. An additional reproduction using 1,824 images confirmed end-to-end pipeline execution and exposed important limitations regarding small-sample generalization and quantization. The results indicate that edge inference can substantially reduce communication overhead while preserving classification performance, provided that deployment estimates are validated on physical hardware and under real field conditions.

Keywords: Edge AI; precision agriculture; computer vision; MobileNetV2; TensorFlow Lite; edge computing.

1. Introdução

A agricultura de precisão depende cada vez mais de sensores, imagens e modelos de aprendizado de máquina para apoiar decisões sobre sanidade vegetal, irrigação e uso localizado de insumos. Entretanto, a adoção de soluções baseadas exclusivamente em nuvem encontra uma restrição prática em áreas rurais: imagens possuem volume elevado e a conectividade pode ser intermitente, cara ou limitada. Nesse cenário, a computação de borda desloca a inferência para próximo da fonte dos dados, reduzindo a necessidade de tráfego contínuo e permitindo respostas locais mesmo quando a conexão externa está indisponível (SHI et al., 2016; ZHANG; CAO; DONG, 2020).

Em visão computacional agrícola, redes neurais convolucionais tornaram possível classificar sintomas visuais de doenças em folhas com alto desempenho em bases controladas. Mohanty, Hughes e Salathé (2016) demonstraram a viabilidade do diagnóstico por imagens utilizando o PlantVillage, enquanto arquiteturas móveis, como a MobileNetV2, reduziram o custo computacional por meio de convoluções separáveis em profundidade e blocos residuais invertidos (SANDLER et al., 2018). Estudos recentes reforçam a tendência de aproximar a inteligência artificial do campo: Nyakuri et al. (2025) apresentaram um dispositivo de borda com Raspberry Pi voltado à detecção de pragas e doenças, e Ugwah e Abolghasemi (2025) mostraram que arquiteturas derivadas de MobileNet podem combinar elevada acurácia com baixo consumo de memória.

O problema de pesquisa deste trabalho é, portanto, como executar classificação visual agrícola em hardware de borda e, simultaneamente, reduzir o overhead de rede sem degradar de forma substancial o desempenho do modelo. A lacuna abordada está na integração explícita entre classificação local, compressão do modelo e política de transmissão seletiva: em vez de enviar imagens completas para processamento remoto, o nó de borda transmite somente metadados de alerta, como classe prevista, confiança, instante e localização.

O objetivo geral é desenvolver e avaliar um pipeline de Edge AI baseado em MobileNetV2 e TensorFlow Lite capaz de classificar condições foliares localmente e reduzir o tráfego de comunicação em aplicações agrícolas. Como objetivos específicos, busca-se: (i) treinar a MobileNetV2 sobre o PlantVillage; (ii) comparar versões FP32, INT8 PTQ e INT8 QAT; (iii) analisar acurácia, F1-score, tamanho do modelo e latência; (iv) estimar a economia de tráfego obtida com o envio de alertas em lugar de imagens; e (v) documentar limitações de reprodução, de hardware e de generalização para campo real.

A relevância da proposta está na possibilidade de reduzir dependência de infraestrutura de comunicação e de nuvem, preservando privacidade e tornando a solução mais adequada a locais com conectividade restrita. O trabalho também contribui ao separar explicitamente métricas efetivamente obtidas, estimativas de implantação e resultados de reprodução reduzida, evitando que indicadores derivados analiticamente sejam interpretados como medições físicas. O

restante do artigo está organizado em Referencial Teórico, Metodologia, Resultados e discussão, Conclusão e Referências bibliográficas, conforme o modelo oficial da FCI.

2. Referencial Teórico

2.1 Computação de borda e Edge AI

Edge Computing é um paradigma no qual processamento, armazenamento e decisões são deslocados da nuvem central para recursos computacionais próximos da origem dos dados. A principal consequência é a redução de latência e de tráfego, além de maior tolerância a falhas de conectividade. Quando modelos de aprendizado de máquina são executados diretamente nesses recursos, emprega-se o termo Edge AI. Em sistemas agrícolas, essa combinação é especialmente relevante porque câmeras geram dados volumosos, enquanto enlaces rurais podem ter baixa largura de banda ou disponibilidade irregular (SHI et al., 2016).

A literatura recente evidencia que o processamento local já é tecnicamente viável em plataformas acessíveis. Nyakuri et al. (2025), por exemplo, integraram um modelo leve a um Raspberry Pi 5 para detecção de pragas e doenças, reportando inferência em dezenas de milissegundos e baixa dependência de conectividade externa. Embora o hardware e o modelo não sejam idênticos aos deste trabalho, esse resultado reforça a plausibilidade arquitetural de sistemas agrícolas de inferência local.

2.2 Redes neurais convolucionais e MobileNetV2

Redes neurais convolucionais (CNNs) extraem representações hierárquicas de imagens por meio de filtros aprendidos. Em tarefas de sanidade vegetal, camadas iniciais capturam bordas, cores e texturas, enquanto camadas mais profundas combinam essas pistas em padrões relacionados a lesões, manchas e alterações morfológicas. O PlantVillage tornou-se uma referência para avaliação de modelos de classificação de doenças foliares e ajudou a consolidar o uso de CNNs nesse domínio (HUGHES; SALATHÉ, 2015; MOHANTY; HUGHES; SALATHÉ, 2016).

A MobileNetV2 foi projetada para cenários com recursos computacionais restritos. Sua arquitetura usa convoluções separáveis em profundidade, gargalos lineares e blocos residuais invertidos, reduzindo operações e parâmetros em comparação a redes convencionais de maior porte (SANDLER et al., 2018). A escolha é compatível com o objetivo deste trabalho de manter inferência local em CPU ARM e produzir um modelo compacto. Trabalhos posteriores continuam explorando variantes da família MobileNet para diagnóstico vegetal, incluindo modelos de 2025 com memória inferior a poucos megabytes (UGWAH; ABOLGHASEMI, 2025).

2.3 TensorFlow Lite e quantização

TensorFlow Lite é um runtime voltado à inferência em dispositivos móveis e embarcados. Uma das principais técnicas de otimização é a quantização, que reduz a precisão numérica dos pesos e, em alguns casos, das ativações. Na quantização pós-treinamento (PTQ), a conversão ocorre após o ajuste do modelo; no Quantization-Aware Training (QAT), o treinamento simula os efeitos da quantização para permitir adaptação dos pesos. Em operações inteiras de 8 bits, a memória e o custo de execução podem ser significativamente menores do que em ponto flutuante de 32 bits (JACOB et al., 2018).

O benefício da quantização, entretanto, não é garantido em qualquer regime de treino. Quantidade de dados, número de épocas, estratégia de calibração e camadas quantizadas afetam o resultado. Por essa razão, este artigo apresenta separadamente os valores oficiais do

treinamento completo e os valores obtidos em uma execução reduzida do pipeline, na qual o QAT teve comportamento inferior ao PTQ.

2.4 Comunicação de baixa largura de banda e redução de overhead

A transmissão seletiva complementa a inferência na borda. Em vez de transportar a imagem que originou a decisão, o nó pode enviar somente uma estrutura compacta de alerta. LoRaWAN é direcionado a aplicações de longa distância e baixo consumo, com payload limitado, enquanto MQTT é um protocolo leve de mensageria publish/subscribe frequentemente utilizado para integração de dispositivos IoT. A proposta deste trabalho usa MQTT no pipeline de software e considera LoRaWAN como meio de comunicação de campo a ser integrado fisicamente em etapa futura.

A redução de overhead depende diretamente da razão entre o tamanho da imagem, a frequência de captura, a proporção de eventos que geram alerta e o tamanho do payload. Logo, a economia de tráfego apresentada neste trabalho é uma estimativa analítica baseada em parâmetros de operação e não deve ser interpretada como medição em uma rede LoRaWAN real.

2.5 Trabalhos relacionados e posicionamento

Mohanty, Hughes e Salathé (2016) estabeleceram uma referência importante para classificação de doenças foliares em ambiente controlado, porém sem foco na implantação embarcada ou no custo de comunicação. Sandler et al. (2018) forneceram a base arquitetural para modelos compactos com a MobileNetV2. Já Nyakuri et al. (2025) demonstraram a integração contemporânea de CNN leve, Raspberry Pi e comunicação IoT em um dispositivo agrícola. Ugwah e Abolghasemi (2025) reforçaram a tendência de modelos extremamente leves derivados de MobileNet para classificação de doenças de folhas.

O diferencial do presente projeto não está apenas na acurácia, mas na avaliação conjunta de classificação, tamanho do modelo, inferência embarcada estimada e redução de tráfego. Essa visão de sistema busca responder a uma restrição operacional típica do campo: mesmo um classificador acurado pode ser impraticável se exigir upload constante de imagens ou hardware de alto custo.

3. Metodologia

A pesquisa possui caráter aplicado e abordagem quantitativa experimental. O objeto de avaliação é um pipeline computacional de classificação de imagens e comunicação seletiva. A metodologia foi organizada para permitir reprodução do treinamento, quantização e geração de alertas, além de distinguir três níveis de evidência: resultados oficiais reportados para o dataset completo, execução reproduzida em amostra reduzida e estimativas de implantação em Raspberry Pi 4 e rede de baixa largura de banda.

3.1 Dataset e preparação dos dados

O dataset utilizado é o PlantVillage, coleção pública de imagens de folhas saudáveis e doentes. A versão adotada no projeto contém 54.306 imagens distribuídas em 38 classes relacionadas a 14 espécies vegetais e diferentes condições de saúde (HUGHES; SALATHÉ, 2015). As imagens são redimensionadas para 224×224 pixels e processadas em RGB. O conjunto completo é dividido em treino, validação e teste na proporção 70%/15%/15%, com data augmentation por rotação, espelhamento, zoom e variação de brilho.

É importante delimitar o escopo: o PlantVillage é adequado à classificação de doenças e folhas saudáveis, mas foi adquirido predominantemente em condições controladas. Ele não constitui, por si só, uma base específica e abrangente de estresse hídrico. Assim, a validação

quantitativa principal deste trabalho refere-se à classificação foliar das classes do PlantVillage. A detecção específica de estresse hídrico permanece como extensão do sistema e demanda dados rotulados próprios, potencialmente incluindo sensores ou imagens multiespectrais.

Tabela 1. Configuração experimental do pipeline principal

Elemento	Configuração
Dataset	PlantVillage – 54.306 imagens, 38 classes
Entrada	RGB, 224 × 224 pixels
Divisão	70% treino / 15% validação / 15% teste
Backbone	MobileNetV2 pré-treinada em ImageNet
Treinamento oficial	50 épocas
Otimização	Adam; fine-tuning
Conversão	TensorFlow Lite FP32, INT8 PTQ e INT8 QAT
Métricas	Acurácia, F1-score macro, tamanho do modelo, latência e tráfego
Comunicação	Alerta estruturado via MQTT; LoRaWAN previsto para integração física

3.2 Treinamento, quantização e inferência

A MobileNetV2 é inicializada com pesos do ImageNet e ajustada às 38 classes do PlantVillage. O modelo em ponto flutuante funciona como baseline. Em seguida, são geradas duas versões INT8. Na PTQ, o modelo treinado é convertido com calibração representativa. No QAT, camadas compatíveis são ajustadas considerando os efeitos da quantização durante o fine-tuning. A comparação busca medir a perda de desempenho frente à redução de tamanho e ao ganho de eficiência esperado em CPUs ARM.

Na arquitetura operacional, a câmera produz uma imagem, o pré-processamento prepara o tensor de entrada, o modelo executa a inferência local e um filtro de confiança decide se um evento deve ser transmitido. Quando existe uma condição anômala acima do limiar configurado, o software gera um payload compacto com identificador da classe, confiança, timestamp e coordenadas quando disponíveis. Caso contrário, nenhum dado visual precisa deixar o dispositivo.

3.3 Métricas e cálculo do tráfego

Para classificação são consideradas acurácia e F1-score macro. A acurácia mede a proporção global de predições corretas, enquanto o F1 macro calcula a média do equilíbrio entre precisão e recall por classe, reduzindo a influência de classes mais frequentes. Para eficiência são medidos ou reportados o tamanho do arquivo de modelo e o tempo de inferência. Como não houve benchmark em Raspberry Pi 4 físico, os valores de latência apresentados para esse dispositivo são estimados a partir de tempo observado em CPU de desenvolvimento e fator de escala para ARM Cortex-A72.

A redução de tráfego compara um baseline de envio frequente de imagens JPEG com a estratégia de alertas compactos. No cenário adotado no projeto, considera-se uma captura por minuto e geração de mensagens somente quando necessário. O resultado de 99,5% é, portanto, uma estimativa analítica de overhead e não uma medição em gateway LoRaWAN. Essa distinção é mantida em todas as tabelas e discussões.

3.4 Reprodução com amostra reduzida

Além dos resultados oficiais do treinamento completo, o repositório do projeto contém notebooks executados com uma amostra de 1.824 imagens, correspondentes a 48 imagens por classe. Essa execução foi realizada para verificar se as etapas de treinamento, conversão e avaliação funcionam ponta a ponta em ambiente com recursos limitados. Por utilizar aproximadamente trinta vezes menos imagens e poucas épocas de ajuste, seus números não

substituem os resultados oficiais; servem como evidência de executabilidade e como análise de sensibilidade a condições de treino mais restritas.

4. Resultados e discussão

4.1 Resultados oficiais com o dataset completo

Os resultados oficiais reportados na versão N2 do projeto foram obtidos com o PlantVillage completo e 50 épocas de treinamento. A Tabela 2 consolida os indicadores definidos como referência final deste trabalho. O baseline FP32 atingiu 96,4% de acurácia e F1-score macro de 0,962. A PTQ reduziu a acurácia em 0,6 ponto percentual, para 95,8%, enquanto o QAT foi reportado com 96,1%. Ambas as variantes INT8 apresentaram arquivo de 3,6 MB, contra 13,4 MB do modelo FP32.

Tabela 2. Resultados oficiais – PlantVillage completo, 54.306 imagens, 50 épocas

Métrica	FP32	INT8 PTQ	INT8 QAT	Meta
Acurácia	96,4%	95,8%	96,1%	≥ 95%
F1-score (macro)	0,962	0,957	0,960	—
Tamanho do modelo	13,4 MB	3,6 MB	3,6 MB	< 4 MB
Latência estimada RPi 4	~287 ms	74 ms	72 ms	30–100 ms
Redução estimada de tráfego	—	99,5%	99,5%	≥ 90%

Nota: as latências em Raspberry Pi 4 não foram medidas em um dispositivo físico; são estimativas derivadas de medições em CPU de desenvolvimento com fator de escala para ARM Cortex-A72. A redução de tráfego também é analítica e depende das premissas operacionais adotadas.

A principal evidência favorável à arquitetura é o trade-off entre compactação e desempenho. O PTQ reduz o arquivo de 13,4 MB para 3,6 MB, uma diminuição aproximada de 73%, enquanto mantém acurácia acima de 95%. Para um nó de borda, essa redução simplifica armazenamento, carregamento do modelo e transferência de atualizações. A diferença entre PTQ e QAT nos números oficiais é pequena: 0,3 ponto percentual de acurácia em favor do QAT. Essa margem, entretanto, deve ser interpretada com cautela diante dos resultados da reprodução reduzida discutidos adiante.

As latências estimadas de 74 ms e 72 ms para PTQ e QAT, respectivamente, se situam na meta de 30 a 100 ms. Esses valores são coerentes com a ordem de grandeza encontrada em literatura recente de Edge AI agrícola, mas ainda precisam de validação física no Raspberry Pi 4 específico do projeto. Nyakuri et al. (2025), usando outro modelo e Raspberry Pi 5, demonstraram que inferência local em dezenas de milissegundos é possível, o que sustenta a plausibilidade, mas não substitui o benchmark requerido para esta implementação.

4.2 Reprodução em amostra reduzida

Na execução documentada no repositório com 1.824 imagens, o comportamento foi diferente do conjunto oficial. O FP32 atingiu 81,91% de acurácia e o PTQ, 82,66%. O QAT, porém, caiu para 58,47%. Essa divergência é importante porque mostra que o QAT é sensível à quantidade de dados e ao regime de fine-tuning; uma técnica projetada para mitigar perda de quantização pode piorar o modelo quando há poucas épocas e poucos exemplos.

Tabela 3. Reprodução do pipeline em amostra reduzida – 1.824 imagens

Modelo	Acurácia	F1 macro	Tamanho	Latência RPi 4 estimada
MobileNetV2 FP32	81,91%	0,813	9,74 MB	~189 ms
INT8 PTQ	82,66%	0,791	2,90 MB	~45 ms
INT8 QAT	58,47%	0,556	3,84 MB	~48 ms

Esses resultados não substituem a Tabela 2. Seu papel é comprovar que o pipeline do repositório executa de ponta a ponta e expor a necessidade de reproduzir o QAT no dataset completo antes de tratar sua superioridade sobre PTQ como definitivamente confirmada. Em termos de engenharia, o PTQ mostrou-se a opção mais previsível na amostra reduzida, pois preservou a acurácia e produziu o menor arquivo entre as versões executadas nesse cenário.

4.3 Redução de overhead de rede

A redução estimada de 99,5% decorre da mudança do objeto transmitido: imagens completas deixam de ser o dado padrão e passam a ser substituídas por mensagens compactas. Essa decisão arquitetural ataca diretamente o principal gargalo de conectividade do projeto. O ganho é particularmente relevante para LPWAN, em que a largura de banda é reduzida e a energia de transmissão pode representar parcela importante do consumo do nó.

O indicador, contudo, não mede perdas de pacote, duty cycle, alcance, retransmissões ou congestionamento de uma rede LoRaWAN real. O pipeline atual usa MQTT e calcula o benefício com base no tamanho dos payloads e nas premissas de captura/alerta. Portanto, o resultado é forte como análise de volume de dados, mas não equivale a um ensaio de telecomunicações em campo. A próxima etapa experimental deve incluir gateway LoRaWAN físico e medição de bytes efetivamente transmitidos, consumo energético, taxa de entrega e latência fim a fim.

4.4 Limitações, validade e aspectos éticos

A primeira limitação é o domínio visual. O PlantVillage foi coletado em cenário controlado, com fundos e iluminação mais homogêneos do que os encontrados em lavouras. Modelos podem aprender correlações específicas do dataset e sofrer queda de desempenho diante de oclusões, sombras, múltiplas folhas e variações de câmera. Por isso, a acurácia oficial não deve ser extrapolada diretamente para campo real. A ausência de classes específicas de estresse hídrico também limita a validação dessa parte do título do projeto; sua implementação completa requer base complementar e protocolo experimental dedicado.

A segunda limitação é de hardware. As latências de Raspberry Pi 4 são estimadas. Sem o dispositivo físico, não se observam efeitos de temperatura, throttling, versão do runtime, número de threads, resolução da câmera e carga simultânea de comunicação. A terceira limitação é de rede: não houve integração física com gateway LoRaWAN; assim, os 99,5% representam economia analítica de volume, não desempenho de enlace.

Do ponto de vista ético, o sistema deve funcionar como ferramenta de apoio à decisão e não como substituto automático de avaliação agrônômica. Falsos positivos podem incentivar aplicação desnecessária de defensivos, enquanto falsos negativos podem retardar intervenções. O processamento local reduz exposição de imagens e favorece soberania de dados, mas metadados de alertas ainda podem revelar informações sobre localização e condição da lavoura. O desenho operacional deve, portanto, manter supervisão humana, registrar confiança das predições e proteger a comunicação.

5. Conclusão

Este trabalho analisou a viabilidade de um pipeline de Edge AI para classificação visual agrícola e redução do overhead de rede em ambientes com conectividade limitada. A solução combina MobileNetV2, TensorFlow Lite, quantização INT8 e transmissão seletiva de alertas, deslocando a inferência para o nó de borda e evitando o envio contínuo de imagens. O problema de pesquisa foi abordado de forma conjunta: o desempenho de classificação foi avaliado ao lado de tamanho do modelo, latência estimada e volume de comunicação.

Nos resultados oficiais com o PlantVillage completo, o FP32 alcançou 96,4% de acurácia; o INT8 PTQ obteve 95,8% e o INT8 QAT, 96,1%. As versões quantizadas apresentaram 3,6 MB, aproximadamente 73% menores que o FP32 de 13,4 MB. As latências projetadas para Raspberry Pi 4 foram de 74 ms no PTQ e 72 ms no QAT, e a estratégia de alertas produziu redução analítica de 99,5% no tráfego. Esses indicadores atendem às metas definidas para a versão oficial do projeto.

A principal contribuição é demonstrar que a otimização não deve ser analisada apenas como problema de acurácia: compactação do modelo e política de comunicação fazem parte do mesmo sistema. A reprodução com 1.824 imagens também trouxe uma contribuição metodológica ao mostrar que o QAT pode degradar fortemente em condições restritas, reforçando a necessidade de reproduzir o treinamento completo antes de concluir pela superioridade dessa técnica.

As limitações centrais são a ausência de benchmark físico no Raspberry Pi 4, a estimativa analítica do tráfego sem gateway LoRaWAN real, o uso de um dataset controlado e a falta de uma base específica para validação de estresse hídrico. Como trabalhos futuros, recomenda-se executar PTQ e QAT no dataset completo em ambiente reprodutível, medir latência e consumo diretamente no Raspberry Pi 4, integrar o gateway LoRaWAN, realizar testes em campo e incorporar dados específicos de estresse hídrico, incluindo sensores ambientais ou imagens multiespectrais. Essas etapas permitirão transformar a validação de laboratório em uma avaliação completa de implantação agrícola.

6. Referências bibliográficas

- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR 6023: informação e documentação: referências: elaboração. Rio de Janeiro: ABNT, 2018.
- HUGHES, D. P.; SALATHÉ, M. An open access repository of images on plant health to enable the development of mobile disease diagnostics through machine learning and crowdsourcing. arXiv preprint arXiv:1511.08060, 2015.
- JACOB, B. et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference. In: IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Proceedings [...]. 2018. p. 2704-2713.
- LoRa ALLIANCE. LoRaWAN 1.0.4 Specification. 2020. Disponível em: https://loralliance.org/resource_hub/lorawan-104-specification-package/. Acesso em: 7 out. 2026.
- MOHANTY, S. P.; HUGHES, D. P.; SALATHÉ, M. Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, v. 7, art. 1419, 2016. DOI: 10.3389/fpls.2016.01419.
- NYAKURI, J. P.; NKUNDINEZA, C.; GATERA, O.; NKURIKIYEYEU, K.; MWITENDE, G. AI and IoT-powered edge device optimized for crop pest and disease detection. *Scientific Reports*, v. 15, art. 22905, 2025. DOI: 10.1038/s41598-025-06452-5.
- SANDLER, M.; HOWARD, A.; ZHU, M.; ZHMOGINOV, A.; CHEN, L.-C. MobileNetV2: inverted residuals and linear bottlenecks. In: IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Proceedings [...]. 2018. p. 4510-4520.
- SHI, W.; CAO, J.; ZHANG, Q.; LI, Y.; XU, L. Edge computing: vision and challenges. *IEEE Internet of Things Journal*, v. 3, n. 5, p. 637-646, 2016. DOI: 10.1109/JIOT.2016.2579198.
- TENSORFLOW. TensorFlow Lite: deploy machine learning models on mobile and edge devices. 2024. Disponível em: <https://www.tensorflow.org/lite>. Acesso em: 7 out. 2026.
- UGWAH, V. N.; ABOLGHASEMI, V. Optimised MobileNet for very lightweight and accurate plant leaf disease detection. *Scientific Reports*, v. 15, art. 43690, 2025. DOI: 10.1038/s41598-025-27393-z.

ZHANG, X.; CAO, Z.; DONG, W. Overview of edge computing in the agricultural Internet of Things: key technologies, applications, challenges. IEEE Access, v. 8, p. 141748-141761, 2020.

UNIVERSIDADE PRESBITERIANA MACKENZIE. Faculdade de Computação e Informática. Template de artigo do trabalho de conclusão de curso da FCI. São Paulo: UPM, 2026.