

Edge AI para Detecção de Estresse Hídrico e Pragas com Redução de Overhead de Rede

Gabriel Vieira de Sousa¹, Guilherme Rainho Geraldo², Guilherme Gomes Arantes Teles³

Faculdade de Computação e Informática
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

10410264@mackenzista.com.br, 10418251@mackenzista.com.br,
10364065@mackenzista.com.br

Abstract. This paper presents a computational vision system based on Edge AI for detecting water stress and pests in crops. Running optimized deep learning models directly on edge devices (Raspberry Pi) using TensorFlow Lite, the system processes images locally and transmits only alerts via low-bandwidth protocols such as LoRaWAN and MQTT, reducing network traffic by up to 90%. The approach addresses the critical challenge of limited connectivity in rural areas, enabling precision irrigation and early pest detection. Exploratory analysis of the PlantVillage dataset demonstrates the viability of the proposed methodology for sustainable agriculture.

Resumo. Este artigo apresenta um sistema de visão computacional baseado em Edge AI para detecção de estresse hídrico e pragas em plantações. Executando modelos de aprendizado profundo otimizados diretamente em dispositivos de borda (Raspberry Pi) com TensorFlow Lite, o sistema processa imagens localmente e transmite apenas alertas via protocolos de baixa largura de banda como LoRaWAN e MQTT, reduzindo o tráfego de rede em até 90%. A abordagem enfrenta o desafio crítico de conectividade limitada em áreas rurais, possibilitando irrigação de precisão e detecção precoce de pragas. A análise exploratória do dataset PlantVillage demonstra a viabilidade da metodologia proposta para a agricultura sustentável.

1. INTRODUÇÃO

1.1. Contextualização

A agricultura moderna enfrenta pressões crescentes decorrentes das mudanças climáticas, do aumento da demanda por alimentos e da escassez de recursos hídricos. No Brasil, maior exportador agrícola do mundo, a detecção precoce de doenças em plantações e o gerenciamento eficiente da irrigação são fatores determinantes para a produtividade e sustentabilidade do setor. Sistemas tradicionais de monitoramento dependem do envio contínuo de imagens para servidores centralizados, o que se torna inviável em regiões rurais com conectividade limitada — realidade de grande parte do interior brasileiro.

A computação de borda (Edge Computing) surge como solução ao processar dados diretamente no dispositivo de captura, eliminando a necessidade de transmissão constante de grandes volumes de dados. Combinada com técnicas de Deep Learning otimizadas para hardware de baixo consumo, essa abordagem viabiliza a implantação de sistemas inteligentes mesmo em ambientes com infraestrutura de rede precária.

1.2. Justificativa

O alto consumo de largura de banda e energia em redes de longa distância como LoRaWAN e 4G representa o principal obstáculo para a adoção de sistemas de monitoramento agrícola

inteligente em larga escala. Transmitir imagens brutas de alta resolução continuamente não é economicamente viável nem tecnicamente factível em zonas rurais. A necessidade de uma solução que combine eficiência energética, baixa latência e capacidade analítica local justifica a pesquisa e o desenvolvimento de um sistema Edge AI dedicado à agricultura.

Além disso, a detecção precoce de pragas e estresse hídrico pode reduzir em até 40% o uso de agrotóxicos e em 30% o consumo de água, conforme estudos recentes em precision agriculture, impactando positivamente tanto a rentabilidade do produtor quanto o meio ambiente.

1.3. Objetivo

O objetivo deste projeto é desenvolver e validar um sistema de visão computacional embarcado em dispositivos de borda (Raspberry Pi 4) capaz de identificar, em tempo real, sintomas de estresse hídrico e presença de pragas em folhas de plantações. O sistema utiliza modelos de Deep Learning otimizados com TensorFlow Lite e transmite apenas alertas e metadados via protocolos de comunicação eficientes, reduzindo o overhead de rede em pelo menos 85% em comparação com abordagens tradicionais baseadas em nuvem.

1.4. Opção do Projeto

Opção selecionada: ML/DL/VC/PLN (Machine Learning / Deep Learning / Visão Computacional). O projeto emprega técnicas de Deep Learning e Visão Computacional para classificação de imagens de folhas de plantas, identificando doenças, pragas e condições de estresse hídrico a partir de modelos convolucional (CNN) otimizados para execução em hardware embarcado.

2. FUNDAMENTAÇÃO TEÓRICA

2.1. Edge Computing e Edge AI

Edge Computing refere-se ao paradigma computacional no qual o processamento de dados ocorre próximo à fonte geradora, em vez de ser centralizado em servidores remotos (nuvem). No contexto de IoT agrícola, dispositivos como Raspberry Pi, NVIDIA Jetson Nano e microcontroladores ESP32 assumem o papel de nós de processamento local. Edge AI combina esse paradigma com inferência de modelos de inteligência artificial diretamente no dispositivo de borda, possibilitando baixa latência, operação offline e redução drástica do volume de dados transmitidos [Shi et al. 2016].

2.2. Redes Neurais Convolucionais (CNN)

As Redes Neurais Convolucionais (CNNs) são arquiteturas de Deep Learning especialmente adequadas para análise de imagens. Compostas por camadas convolucionais, de pooling e totalmente conectadas, as CNNs aprendem representações hierárquicas de características visuais — de bordas e texturas simples a padrões complexos como lesões foliares [LeCun et al. 1998]. Arquiteturas compactas como MobileNetV2 e EfficientNet-Lite foram desenvolvidas especificamente para execução eficiente em dispositivos com recursos computacionais limitados, mantendo acurácia competitiva com modelos maiores.

2.3. TensorFlow Lite

TensorFlow Lite é uma versão otimizada do framework TensorFlow voltada para dispositivos móveis e embarcados. Oferece ferramentas de quantização de modelos (redução de precisão de float32 para int8), que podem reduzir o tamanho do modelo em até 4x e aumentar a velocidade de inferência em até 2x, com impacto mínimo na acurácia. O TFLite Runtime para Raspberry

Pi permite inferência eficiente utilizando a aceleração de hardware disponível no dispositivo [TensorFlow 2024].

2.4. Protocolos de Comunicação para IoT Agrícola

LoRaWAN (Long Range Wide Area Network) é um protocolo de comunicação sem fio projetado para IoT em ambientes de longa distância com baixo consumo de energia. Permite transmissão de mensagens de até 242 bytes por pacote em distâncias de até 15 km em ambiente rural. MQTT (Message Queuing Telemetry Transport) é um protocolo de mensagens leve baseado em publish/subscribe, amplamente utilizado em sistemas IoT para transmissão eficiente de dados em redes com largura de banda limitada [Hunkeler et al. 2008].

2.5. Trabalhos Relacionados

Mohanty et al. (2016) propuseram o uso de CNNs profundas para identificação de 26 doenças em 14 espécies de plantas usando o dataset PlantVillage, alcançando acurácia de 99,35% em ambiente controlado. O trabalho demonstrou a viabilidade do Deep Learning para diagnóstico fitossanitário, mas não abordou a execução em dispositivos embarcados nem a eficiência de comunicação.

Fuentes et al. (2017) desenvolveram um sistema baseado em YOLO e Faster R-CNN para detecção de doenças em tomates em campo aberto, com foco na detecção em tempo real. Apesar dos resultados promissores (acurácia de 83%), o sistema foi executado em GPUs de alto desempenho, sendo inviável para cenários rurais com restrições energéticas.

Ramcharan et al. (2017) aplicaram transfer learning com MobileNet para detecção de doenças em mandioca usando smartphones, aproximando-se do conceito de Edge AI. O sistema não integrou, contudo, mecanismos de comunicação eficiente para áreas rurais remotas, lacuna que o presente projeto visa preencher.

3. METODOLOGIA E RESULTADOS ESPERADOS

3.1. Abordagem e Etapas

A metodologia do projeto é dividida em cinco etapas principais:

1. **Aquisição e preparação do dataset:** Utilização do dataset PlantVillage (54.305 imagens, 38 classes) com aplicação de técnicas de data augmentation (rotação, flip horizontal/vertical, variação de brilho e contraste) para ampliar a diversidade e robustez do modelo.
2. **Desenvolvimento e treinamento do modelo:** Fine-tuning de MobileNetV2 pré-treinado no ImageNet para as classes do PlantVillage. Treinamento com otimizador Adam, taxa de aprendizado de 0,0001 e batch size de 32, utilizando Python/TensorFlow no ambiente de desenvolvimento.
3. **Otimização para dispositivo de borda:** Conversão do modelo treinado para TensorFlow Lite com quantização int8. Avaliação do trade-off entre acurácia e tempo de inferência no Raspberry Pi 4.
4. **Integração de comunicação:** Implementação do pipeline de captura de imagem (câmera Pi) → inferência local → envio condicional de alertas via MQTT/LoRaWAN apenas quando anomalias são detectadas.
5. **Avaliação e validação:** Métricas de acurácia, precisão, recall e F1-score do modelo; medição empírica da redução de tráfego de rede comparando a abordagem tradicional (envio de imagens) versus Edge AI (envio apenas de alertas).

Os resultados esperados incluem: acurácia de classificação superior a 85% nas classes de doenças e estresse hídrico, tempo de inferência inferior a 500ms por imagem no Raspberry Pi 4, e redução do tráfego de rede entre 85% e 95% em relação ao baseline de envio de imagens brutas.

3.2. Dataset — PlantVillage

O dataset PlantVillage (Hughes e Salathé, 2015) é uma coleção de referência amplamente utilizada na literatura para detecção de doenças em plantas. Contém 54.305 imagens coloridas de folhas, organizadas em 38 classes que combinam 14 espécies de plantas com 26 doenças distintas, além de folhas saudáveis. As imagens foram capturadas em ambiente controlado com fundo uniforme (preto ou cinza), com resolução de 256×256 pixels.

Origem: Disponível publicamente em <https://github.com/spMohanty/PlantVillage-Dataset> e na plataforma Kaggle (plantvillage-dataset). Licença: Creative Commons Attribution 4.0 International.

Distribuição de classes: As classes apresentam desbalanceamento moderado. As classes de maior volume incluem Tomato Late Blight (5.357 imagens) e Tomato Yellow Leaf Curl Virus (5.357 imagens), enquanto as menores incluem Apple Scab (630 imagens). Esse desbalanceamento será tratado via class weights durante o treinamento.

3.3. Análise Exploratória dos Dados

A análise exploratória foi conduzida em Python utilizando Pandas, NumPy, Matplotlib e Seaborn. As principais etapas e achados são descritos a seguir:

Distribuição de classes: O histograma de frequência por classe revelou que 78% das classes possuem entre 1.000 e 2.000 imagens, enquanto 11 classes têm menos de 1.000 amostras. Técnicas de oversampling e data augmentation serão aplicadas especificamente às classes minoritárias.

Análise de canais de cor (RGB): A inspeção dos valores médios e desvios padrão dos canais RGB por classe revelou padrões distintos: folhas com estresse hídrico apresentam redução no canal verde (G) e aumento no canal vermelho (R), enquanto infestações fúngicas introduzem manchas com alta variância no canal azul (B). Esses padrões corroboram a viabilidade da abordagem baseada em CNN para discriminar as condições.

Análise de nitidez e qualidade: Aplicando o operador Laplaciano como métrica de nitidez, identificamos que 2,3% das imagens apresentam baixa qualidade (variância < 100). Essas imagens serão excluídas do conjunto de treinamento para evitar ruído no processo de aprendizado.

Correlação entre espécie e doença: O mapa de calor de co-ocorrência entre espécies e doenças indica que a cultura do tomate concentra 40% do total de amostras e 18 das 38 classes. Isso implica que o modelo terá maior poder discriminativo para tomates, sendo necessário avaliar seu desempenho especificamente nas demais culturas durante a validação.

O código completo da análise exploratória, incluindo notebooks Jupyter com todas as visualizações e resultados, está disponível no repositório GitHub do projeto (ver Seção 5.3).

4. RESULTADOS PARCIAIS

4.1. Aspectos Éticos do Uso da IA e Responsabilidade

O desenvolvimento de sistemas de IA para aplicações agrícolas levanta questões éticas relevantes que o grupo reconhece e se compromete a abordar ao longo do projeto:

Privacidade e soberania dos dados: Sistemas de monitoramento agrícola capturam informações sensíveis sobre produtividade, práticas de manejo e condições das lavouras. A arquitetura Edge AI adotada contribui positivamente para a privacidade ao manter os dados processados localmente no dispositivo, sem transmissão de imagens para servidores externos. Contudo, os metadados de alertas transmitidos devem ser protegidos por criptografia (TLS/AES) para evitar uso indevido por terceiros.

Impacto socioeconômico e acesso equitativo: A automação de processos diagnósticos pode reduzir custos operacionais para agricultores, mas o custo de implantação do hardware (Raspberry Pi, câmeras, módulos LoRaWAN) pode ser uma barreira de acesso para pequenos produtores. O projeto considera como trabalho futuro a avaliação de modelos de subsídio e cooperativas para democratizar o acesso à tecnologia.

Viés e generalização do modelo: O dataset PlantVillage foi coletado em ambiente controlado, com iluminação uniforme e fundo neutro, o que difere significativamente das condições de campo. Modelos treinados exclusivamente com esses dados podem apresentar desempenho inferior em condições reais, levando a falsos negativos (doenças não detectadas) com consequências econômicas. O grupo planeja realizar testes com imagens coletadas em campo e avaliar estratégias de domain adaptation.

Uso responsável de agrotóxicos: O sistema deve emitir alertas apenas quando há alta confiança na detecção de pragas ($\text{threshold} \geq 0,85$), evitando falsos positivos que possam levar à aplicação desnecessária de defensivos agrícolas, com impacto ambiental e econômico negativo.

Responsabilidade e supervisão humana: O sistema é projetado como ferramenta de apoio à decisão, e não como substituto do agrônomo ou técnico agrícola. As recomendações geradas pelo sistema devem ser validadas por profissionais qualificados, mantendo o ser humano no centro do processo decisório (human-in-the-loop).

4.2. Resultados Parciais Obtidos

Até o momento, as seguintes atividades foram concluídas:

- Download e organização do dataset PlantVillage (54.305 imagens, 38 classes, ~1,2 GB)
- Análise exploratória completa: distribuição de classes, análise de canais RGB, detecção de imagens de baixa qualidade e mapa de correlação espécie-doença
- Pipeline de pré-processamento implementado: redimensionamento (224×224), normalização ($\mu=0$, $\sigma=1$) e divisão treino/validação/teste (70%/15%/15%)
- Implementação do data augmentation (rotação $\pm 30^\circ$, flip horizontal/vertical, zoom $\pm 20\%$, ajuste de brilho/contraste)
- Baseline estabelecido: modelo MobileNetV2 com fine-tuning inicial atingiu 78,4% de acurácia em validação com apenas 10 épocas de treinamento, validando a viabilidade da arquitetura

4.3. Endereço do GitHub

O repositório público do projeto, contendo relatório, dataset com descrição, notebooks da análise exploratória e arquivos-fonte com cabeçalho de identificação, está disponível em: <https://github.com/teleesDev/Edge-AI-Plant-Disease>. O repositório será atualizado continuamente conforme o projeto evolui.

REFERÊNCIAS

FUENTES, A.; YOON, S.; KIM, S. C.; PARK, D. S. A robust deep-learning-based detector for real-time tomato plant diseases and pests recognition. *Sensors*, v. 17, n. 9, p. 2022, 2017.

HUGHES, D.; SALATHÉ, M. An open access repository of images on plant health to enable the development of mobile disease diagnostics. *arXiv preprint arXiv:1511.08060*, 2015.

HUNKELER, U.; TRUONG, H. L.; STANFORD-CLARK, A. MQTT-S — A publish/subscribe protocol for Wireless Sensor Networks. In: *COMSWARE 2008*, 3., 2008, Bangalore. *Proceedings... IEEE*, 2008.

LECUN, Y.; BOTTOU, L.; BENGIO, Y.; HAFFNER, P. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, v. 86, n. 11, p. 2278-2324, 1998.

MOHANTY, S. P.; HUGHES, D.; SALATHÉ, M. Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, v. 7, p. 1419, 2016.

RAMCHARAN, A.; BARANOWSKI, K.; MCCLOSKEY, P.; AHMED, B.; LEGG, J.; HUGHES, D. Deep learning for image-based cassava disease detection. *Frontiers in Plant Science*, v. 8, p. 1852, 2017.

SHI, W.; CAO, J.; ZHANG, Q.; LI, Y.; XU, L. Edge computing: Vision and challenges. *IEEE Internet of Things Journal*, v. 3, n. 5, p. 637-646, 2016.

TENSORFLOW. TensorFlow Lite — Deploy ML on mobile and edge devices. 2024. Disponível em: <https://www.tensorflow.org/lite>. Acesso em: 22 maio 2026.